

Projet Final : Audit Data Complet d'une Marketplace E-commerce

Analyse avancée du dataset Olist Brazilian E-commerce

Module : Traitement de Données

Objectif général : réaliser une analyse complète, professionnelle et argumentée d'une marketplace e-commerce réelle à partir de données transactionnelles multi-tables. Le projet doit aboutir à des indicateurs fiables, des visualisations pertinentes et des recommandations business justifiées.

1 Contexte du projet

Vous travaillez comme équipe de data analysts pour une marketplace e-commerce. Cette plateforme met en relation des clients et des vendeurs. Elle souhaite comprendre en profondeur son activité afin d'améliorer :

- la satisfaction des clients ;
- les délais de livraison ;
- la performance des vendeurs ;
- la rentabilité des catégories de produits ;
- la qualité globale du service.

La direction vous demande de produire une analyse complète à partir de données historiques réelles. Votre travail ne doit pas se limiter à produire des graphiques : vous devez nettoyer les données, construire des indicateurs, interpréter les résultats et proposer des décisions concrètes.

2 Dataset utilisé

Le projet utilise le dataset public suivant :

<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Nom du dataset : **Brazilian E-Commerce Public Dataset by Olist**

Ce dataset contient environ 100 000 commandes réalisées sur une marketplace brésilienne. Les données sont anonymisées et organisées en plusieurs fichiers CSV.

2.1 Tables principales

Fichier	Description
<code>olist_orders_dataset.csv</code>	Informations sur les commandes : statut, dates d'achat, de livraison et date estimée.
<code>olist_customers_dataset.csv</code>	Informations sur les clients : identifiant, ville, état, code postal.
<code>olist_order_items_dataset.csv</code>	Détails des articles commandés : produit, vendeur, prix, frais de livraison.
<code>olist_products_dataset.csv</code>	Informations sur les produits : catégorie, dimensions, poids.
<code>olist_sellers_dataset.csv</code>	Informations sur les vendeurs : ville, état, code postal.
<code>olist_order_payments_dataset.csv</code>	Informations sur les paiements : type, montant, nombre de versements.
<code>olist_order_reviews_dataset.csv</code>	Avis clients : note, commentaire, dates de réponse.
<code>olist_geolocation_dataset.csv</code>	Données géographiques par code postal.
<code>product_category_name_translation.csv</code>	Traduction des catégories de produits du portugais vers l'anglais.

3 Travail demandé

Le projet doit être réalisé en groupes de 2 à 4 étudiants. Chaque groupe doit produire une analyse structurée, reproductible et lisible.

3.1 Étape 1 : Compréhension, chargement et exploration des données

Vous devez :

- charger tous les fichiers CSV nécessaires avec `pandas` ;
- afficher la taille de chaque table ;
- identifier les clés primaires et les clés de jointure ;
- comprendre la signification des colonnes principales ;
- construire un schéma simple des relations entre les tables.

Éléments à produire :

1. un tableau récapitulatif des tables utilisées ;
2. un schéma simple des relations entre les tables ;
3. une justification des tables retenues pour l'analyse finale.

3.2 Étape 2 : Nettoyage, préparation et construction de la table finale

Vous devez effectuer un nettoyage rigoureux des données.

- vérifier les valeurs manquantes ;
- vérifier les doublons ;
- convertir les colonnes de dates au bon format ;
- vérifier les incohérences dans les dates ;
- traiter les commandes annulées ou indisponibles ;
- documenter toutes les décisions de nettoyage.

Questions difficiles :

1. Quels types de valeurs manquantes doivent être supprimés, conservés ou remplacés ?
2. Les commandes annulées doivent-elles être incluses dans toutes les analyses ? Justifiez.
3. Existe-t-il des incohérences importantes pouvant fausser les conclusions finales ?

Vous devez ensuite construire une table finale d'analyse en réalisant les jointures nécessaires. Après chaque jointure, vous devez vérifier le nombre de lignes avant et après.

3.3 Étape 3 : Construction des indicateurs et analyse globale

Vous devez créer de nouvelles colonnes utiles pour l'analyse :

- `chiffre_affaires` : somme des prix des articles ;
- `frais_livraison_total` : somme des frais de livraison ;
- `montant_total` : prix + frais de livraison ;
- `delai_livraison` : nombre de jours entre achat et livraison ;
- `retard_livraison` : différence entre date de livraison réelle et date estimée ;
- `est_en_retard` : oui/non ;
- `mois_achat` et `annee_achat` ;
- `note_faible` : oui si la note client est inférieure ou égale à 2 ;
- `score_vendeur` : indicateur de qualité par vendeur.

Questions obligatoires :

1. Quel est le chiffre d'affaires total ?
2. Quel est le panier moyen ?
3. Quelle est l'évolution mensuelle du chiffre d'affaires ?
4. Quels mois, catégories ou régions contribuent le plus à la performance globale ?

Visualisations attendues :

- courbe du chiffre d'affaires mensuel ;
- classement des catégories ou régions les plus importantes ;
- histogramme du panier moyen ou des montants de commande.

3.4 Étape 4 : Analyses métier approfondies

Cette étape constitue le cœur du projet. Vous devez analyser la satisfaction client, la livraison, les vendeurs, les produits, les catégories et les zones géographiques.

A. Satisfaction client

1. Les commandes en retard ont-elles une note plus faible ?
2. Le délai de livraison influence-t-il la note ?
3. Les frais de livraison influencent-ils la satisfaction ?
4. Certaines catégories de produits reçoivent-elles plus de mauvaises notes ?
5. Certains vendeurs reçoivent-ils beaucoup de mauvaises notes ?

B. Logistique et livraison

1. Quel est le pourcentage de commandes livrées en retard ?
2. Quels états ont le plus fort taux de retard ?
3. Les vendeurs éloignés des clients causent-ils plus de retard ?
4. Les produits lourds ou volumineux sont-ils livrés plus lentement ?

C. Vendeurs

1. Quels sont les vendeurs qui génèrent le plus de chiffre d'affaires ?
2. Existe-t-il des vendeurs avec beaucoup de ventes mais une satisfaction faible ?
3. Existe-t-il des vendeurs avec un taux de retard élevé ?
4. Quels vendeurs devraient être surveillés par la marketplace ?

D. Produits et catégories

1. Quelles catégories génèrent le plus de chiffre d'affaires ?
2. Quelles catégories sont rentables mais problématiques ?
3. Quelles catégories combinent mauvaise satisfaction, retard ou frais de livraison élevés ?
4. Les produits lourds ou volumineux sont-ils associés à plus de problèmes ?

Vous devez identifier au moins :

- 5 catégories performantes ;
- 5 catégories problématiques ;
- 3 catégories à développer ;
- 3 catégories à surveiller.

E. Analyse géographique

1. Quels états génèrent le plus de chiffre d'affaires ?
2. Quels états ont les plus grands problèmes de livraison ?
3. Existe-t-il des régions très rentables mais mal servies ?
4. La distance ou différence d'état entre vendeur et client influence-t-elle la satisfaction ?

Vous pouvez utiliser les données de géolocalisation pour enrichir l'analyse. Si vous ne les utilisez pas, vous devez justifier ce choix.

Visualisations attendues :

- comparaison des notes entre commandes en retard et commandes à temps ;
- boxplot des délais de livraison ;
- barplot du taux de retard par état ;
- heatmap ou tableau croisé entre état client et état vendeur ;
- classement des vendeurs selon chiffre d'affaires, note moyenne et taux de retard ;
- classement des catégories selon chiffre d'affaires, satisfaction et problèmes logistiques.

3.5 Étape 5 : Synthèse business et recommandations

Votre rapport doit répondre clairement à ces questions finales :

1. Quels sont les trois problèmes les plus importants de la marketplace ?
2. Quelles preuves dans les données soutiennent ces conclusions ?
3. Quels vendeurs ou catégories doivent être surveillés ?
4. Quelles actions concrètes recommandez-vous à la direction ?
5. Quels indicateurs faut-il suivre chaque mois ?

4 Livrables attendus

Chaque groupe doit rendre :

1. un notebook Jupyter complet et propre ;
2. un fichier CSV final nettoyé ou une table finale d'analyse ;
3. un rapport PDF de 8 à 15 pages ;
4. une présentation orale de 10 minutes ;
5. les fichiers de visualisation si nécessaire.

4.1 Notebook

Le notebook doit contenir :

- des titres clairs ;
- du code lisible ;
- des commentaires utiles ;
- des graphiques interprétés ;
- des conclusions après chaque grande partie.

4.2 Rapport

Le rapport doit être une synthèse claire. Il ne doit pas contenir de code et ne doit pas contenir les réponses détaillées à toutes les questions. Les réponses détaillées, les calculs, les tests et le code doivent être dans le notebook.

Le rapport doit contenir :

- introduction et contexte ;
- schéma des tableaux et des relations entre les tableaux ;
- résumé de la préparation et du nettoyage ;
- principaux KPI ;
- 5 à 8 graphiques importants avec interprétation courte ;
- principales conclusions ;
- recommandations business ;
- limites de l'analyse.

4.3 Présentation orale

La présentation doit être courte, visuelle et sans beaucoup de texte. Elle doit durer environ 10 minutes.

Structure conseillée :

- contexte et objectif du projet ;
- schéma simple des données utilisées ;
- les résultats importants ;
- les graphiques clés ;
- problèmes identifiés ;
- recommandations finales.

Chaque diapositive doit contenir peu de texte. Il faut privilégier les graphiques, les chiffres importants et les messages courts.

5 Contraintes techniques

- Langage obligatoire : Python.
- Bibliothèques principales : `pandas`, `numpy`, `matplotlib`, `seaborn`.
- Bibliothèques bonus : `scikit-learn`, `plotly`, `geopandas`.
- Le code doit être reproductible.
- Les chemins de fichiers doivent être organisés.
- Les décisions de nettoyage doivent être expliquées.

6 Erreurs à éviter

- faire seulement des graphiques sans interprétation ;
- oublier de vérifier les valeurs manquantes ;
- faire des jointures sans vérifier le nombre de lignes avant et après ;
- confondre chiffre d'affaires, prix produit et montant total payé ;
- inclure les commandes annulées dans toutes les analyses sans justification ;
- présenter des conclusions sans preuve ;
- utiliser trop de graphiques inutiles ;
- copier du code sans comprendre les résultats.

7 Conseils de travail

1. Commencez par comprendre les tables avant de coder beaucoup.
2. Nettoyez les données progressivement.
3. Après chaque jointure, vérifiez la taille de la table.
4. Créez une table finale d'analyse bien documentée.

5. Posez des hypothèses, puis testez-les avec les données.
6. Chaque graphique doit répondre à une question précise.
7. Terminez par des recommandations concrètes et réalistes.

8 Question finale de direction

À la fin du projet, votre équipe doit être capable de répondre clairement à la question suivante :

Si vous étiez responsables de cette marketplace, quelles décisions prendriez-vous pour augmenter la satisfaction client et améliorer la performance globale ?

Important : chaque étudiant doit maîtriser tout le projet. Pendant la présentation, chaque membre du groupe peut être interrogé sur n'importe quelle partie.